

Optimización de costos

El flujo de cotizaciones de hardware utiliza GPT-5 Min como modelo de IA para las dos tareas principales del proceso:

- 1. Analizar la solicitud enviada por el cliente.
- 2. Generar una **propuesta de hardware** utilizando el catálogo disponible en Airtable.

La elección se basa en que ambas tareas son acotadas, estructuradas y no requieren razonamiento complejo ni procesamiento de grandes volúmenes de documentación. Por este motivo, se prioriza un modelo de menor costo y buena capacidad para extracción estructurada y generación controlada.

Matriz de decisión

Tarea	Modelo / estrategia	Complejidad de la tarea	Necesidad de respuesta inmediata	Costo relativo	Decisión
Analizar solicitud del cliente	GPT-5 Mini	Baja / media	Sí	Bajo	Usado
Generar propuesta de hardware	GPT-5 Mini	Media	Sí	Bajo	Usado
Procesamiento con un modelo de mayor capacidad	Modelo de mayor capacidad	Alta	Sí	Mayor	No necesario para este caso
Procesamiento masivo no interactivo	GPT-5 Mini mediante Batch API	Baja / media	No	Menor a procesamiento síncrono	Alternativa futura

Modelo utilizado

Análisis de solicitud

La primera llamada a IA recibe un mensaje corto del cliente y debe extraer información estructurada como:

- presupuesto;
- tipo de equipo;
- uso principal;

- *software mencionado;*
- *datos faltantes;*
- *resumen de la solicitud.*

La salida esperada es un JSON pequeño y predecible.

Para esta tarea, GPT-5 Mini resulta suficiente porque no se requiere análisis documental extenso ni razonamiento especializado. Utilizar un modelo de mayor capacidad aumentaría el costo sin aportar una mejora significativa para el objetivo del flujo.

Generación de propuesta

La segunda llamada a IA recibe:

- los requerimientos ya estructurados del cliente;
- el presupuesto;
- el uso principal;
- un catálogo reducido proveniente de **Airtable**.

El modelo debe seleccionar productos exclusivamente de ese catálogo y generar una propuesta breve.

La tarea está fuertemente acotada por el prompt y por los datos suministrados, por lo que GPT-5 Mini también resulta adecuado para esta etapa.

Estrategias de optimización

Uso de un único modelo liviano.

Se utiliza GPT-5 Mini en ambas etapas de IA.

Prompts acotados

Los prompts contienen únicamente las instrucciones necesarias para cada tarea. En lugar de solicitar respuestas abiertas, se especifica una estructura de salida concreta.

Salidas JSON estructuradas

Las respuestas del modelo se solicitan exclusivamente en formato JSON.

Máximo de dos llamadas de IA por solicitud completa

Una solicitud completa utiliza únicamente dos llamadas al modelo:

Solicitud

↓

GPT-5 Mini

Analizar solicitud

↓

GPT-5 Mini

Generar propuesta

Catálogo reducido

La propuesta se genera utilizando únicamente productos **activos, con stock y almacenados en Airtable**.

n8n filtra previamente el catálogo antes de enviarlo al modelo.

Conclusión

GPT-5 Mini se utiliza porque las tareas del sistema son concretas y estructuradas: extracción de información y generación de una propuesta basada en un catálogo limitado. El flujo evita procesamiento innecesario mediante validaciones previas y solamente genera una cotización cuando existen datos suficientes.